# ModelDeck 全量离线安装说明

交付版本：1.4.0-dev.1-offline-20260919

目标环境：厂家 Debian 12 ARM64 / CIX P1 / 后摩 LQ50，XH2 驱动与 SDK v1.4.0

制作日期：2026-09-19

## 1. 阅读须知与验收状态

本交付物包含主项目的 UI、管理 Agent、统一 API 网关、12 个 Linux ARM64 镜像、25 个权重型模型的完整文件，以及不需要独立神经网络权重的 democratic-eval-v1 票据识别服务，共 26 个注册模型。安装过程不访问外网，不拉取镜像，不下载模型，不编译项目，也不执行联网 apt/pip 安装。

这是完整制品的开发交付包，版本仍为 development，不是已通过批量新机验收的稳定版。制作时核验全部模型 SHA-256、镜像标签与架构、部署配置和归档完整性；目前没有空白备用设备，未完成新盒子从零安装与断网重启演练。首次正式交付前，必须按第 7 节在一台空白同型号盒子上验收并留存报告。

全量安装不等于全部模型同时运行。全部模型文件与镜像都会安装；默认启动 CoPaw 模式、Guard、CV、ASR、CPU/CIX TTS、票据识别和管理平台。后摩设备上的八种模型模式互斥，通过 UI 切换，不能同时强行启动。

本包不包含操作系统刷机镜像、内核驱动安装程序、旧盒子的密码/API Key、业务 PDF、历史日志、旧版本备份，以及另外部署的 WeKnora、数据库和 ModelRouter 项目。

## 2. 安装前必须满足的条件

- 使用同型号 CIX P1 + 后摩 LQ50 盒子；本包不能用于普通 x86 服务器，也不能直接用于其他加速器。
- 已安装厂家 Debian 12 ARM64 系统和匹配的 XH2 v1.4.0 驱动/SDK。源设备系统内核为 6.6.89-cix-build-generic，厂家系统 BUILD_ID 为 25Q320260821。其他厂家系统版本需要先做兼容性确认。
- `/dev/aipu`、`/dev/xh2a_ctl0` 及其他 XH2 设备节点存在；`/usr/local/houmo-drv-xh2_v1.4.0` 已存在。安装器不会替换驱动或固件。
- 系统中有 `cix` 用户，主目录为 `/home/cix`，安装人员有 sudo 权限。盒子的系统登录密码由交付方提供，与本包生成的 UI 管理密码无关。
- 厂家基础系统已具备 Python 3、curl、tar、gzip、systemd、dpkg、iptables、nftables 等基础组件。预检会列出缺失项；离线安装器不会尝试联网补装。
- 使用空白部署环境：没有已有项目目录和 Docker 容器，不与生产服务混装。已安装 `docker.io` 时会拒绝安装，不会擅自卸载。包内提供 Docker CE 29.7.2、Compose 5.5.0 及对应离线 deb。
- 安装前建议预留 250 GB 可用磁盘空间，用于原始包、解压目录、实际部署和 Docker 数据。安装器会分别检查 `/home/cix` 和 Docker 数据目录所在文件系统。250 GB 指可用空间，不是磁盘标称容量。

- 管理入口使用 TCP 17780，统一 API 使用 TCP 17700。只向可信业务网络开放；不要开放 Docker socket 或内部管理代理。

如果盒子是空盘，先由厂家刷好上述系统与驱动，再执行本文。不要使用本项目安装包代替系统恢复镜像。

## 3. 交付文件及校验

对外交付以下三个文件；安装人员可以通过移动硬盘或内网服务器先行拷贝，正式安装阶段完全离线。

```
houmo-ai-cluster-1.4.0-dev.1-offline-20260919.tar
houmo-ai-cluster-1.4.0-dev.1-offline-20260919.tar.sha256
安装说明.pdf（另附同内容的安装说明.md）
```

最外层使用未压缩 TAR；镜像和运行环境在包内已经压缩，避免对大权重反复压缩。必须用 tar 解包，不要将其当成 ZIP。移动硬盘需要支持大于 4 GB 的单文件，例如 exFAT；FAT32 不适用。实际项目安装目录应位于盒子的 Linux 文件系统，不在 exFAT 移动盘上运行。

将 TAR 与 SHA256 文件放在同一目录，在盒子上执行：

```
PKG=houmo-ai-cluster-1.4.0-dev.1-offline-20260919
sha256sum -c "$PKG.tar.sha256"
```

只有输出 `OK` 才能继续。校验失败应重新拷贝并复核，不得跳过校验。SHA-256 用于检出损坏，分发时还应通过可信渠道核对校验值；本包未实施数字签名。

Windows 交付人员也可以在 PowerShell 中执行：

```
Get-FileHash -Algorithm SHA256 .\houmo-ai-cluster-1.4.0-dev.1-offline-20260919.tar
```

将结果与同名 `.sha256` 文件中的值比较。无需把制作工作目录中的 `build` 文件夹交给安装人员。

## 4. 解包与只读预检

下面假设 TAR 文件位于当前目录，解压到 `/opt/modeldeck-delivery`。也可以选择其他有足够空间的 Linux 文件系统。

```
PKG=houmo-ai-cluster-1.4.0-dev.1-offline-20260919
sudo mkdir -p /opt/modeldeck-delivery
sudo tar -xf "$PKG.tar" -C /opt/modeldeck-delivery
cd "/opt/modeldeck-delivery/$PKG"
sudo bash scripts/install.sh --preflight-only
```

预检会读取全包校验和，并检查架构、系统、驱动节点、cix 用户、基础依赖、端口、已有项目和磁盘空间。只有看到 `PRECHECK PASSED` 才能安装。预检不会安装软件、启动容器或修改现有项目。

出现已有项目/容器提示时，应停止并联系项目维护人员。本包是首次全量安装工具，不是升级器；不要删除现有项目以强行通过预检。

## 5. 执行全量离线安装

在刚才的解压目录中执行：

```
sudo bash scripts/install.sh
```

安装器会再次校验包，然后依次完成：离线安装 Docker、复制全部模型和项目文件、恢复固定运行环境、生成独立凭据、导入锁定镜像、注册 systemd、创建全部模型容器、启动默认服务和真实推理验收。全过程无需互联网。

镜像和模型体积较大，完整校验与复制需要时间。终端会显示当前阶段；不要因为暂时没有新输出就拔盘或断电。建议使用盒子的本地终端或可靠的远程终端连接。当前安装进程依赖执行它的终端，不是后台安装守护进程。

安装完成应看到 `INSTALLATION PASSED`。凭据不会写入安装日志，初始管理密码由每台机器随机生成，不存在统一默认管理密码。安装日志保存在 `/var/log/modeldeck-offline-install/`，阶段记录保存在 `/var/lib/modeldeck-offline-install/state.json`。

如果意外断电或终端中断，先恢复环境、确认没有安装进程仍在运行，再回到同一版本的解压目录执行：

```
sudo bash scripts/install.sh --resume
```

恢复操作会重新校验包，并跳过记录为已完成的安装阶段；未完成阶段会重新执行。不要手工修改阶段记录，不要用其他版本的包恢复。若失败发生在 NPU 启动/验收阶段，应先查看运行诊断，不能反复重试或擅自复位设备。

## 6. 登录 UI 与调用统一 API

通过 `hostname -I` 查看盒子地址。访问 `http://< 盒子 IP>:17780/`，使用下面命令取得初始管理密码；按页面要求登录，不要把操作系统 SSH 密码当成 UI 密码。

```
sudo cat /home/cix/gateway-admin/INITIAL_ADMIN_PASSWORD
```

在 UI 中管理业务 API Key。初始兼容 Key 保存在 `/home/cix/houmo-docker-deployment/.env`，不要将该文件发送给其他人。网关地址为 `http://< 盒子 IP>:17700/v1`，请求使用 `Authorization: Bearer < 业务 Key>`。

下面的本机调用不把 Key 明文写入命令历史：

```
sudo bash -c '
set -a
. /home/cix/houmo-docker-deployment/.env
set +a
curl --fail --silent --show-error \
  -H "Authorization: Bearer $HOUMO_API_KEY" \
  http://127.0.0.1:17700/v1/models
'
```

聊天类请求使用 `/v1/chat/completions`。票据识别使用 `/v1/documents/analyze?model=democratic-eval-v1`，上传原始 PDF/图片字节并设置对应 Content-Type；它不是聊天模型，不能通过聊天接口调用。具体示例见 UI 的“API 参考”。

全部模型已安装并不代表都显示运行中。默认 CoPaw 可用，其他后摩模式未激活是正常现象。通过 UI 的模型管理切换模式，等待健康检查与真实推理通过后再调用该模式对应模型。

## 7. 安装验收与断网重启验收

安装器自动执行当前后摩模式的真实推理、CPU/CIX 视觉和语音模型探针，以及通过网关提交合成票据并核对 36 个选项。验收报告写入：

```
/home/cix/houmo-docker-deployment/state/offline-acceptance.json
```

可以在交付目录重新执行默认验收：

```
sudo python3 scripts/verify_runtime.py
```

新机首次交付前，在没有业务请求的维护窗口，执行全模式验收：

```
sudo python3 scripts/verify_runtime.py --all-modes
```

此操作会依次切换 CoPaw、Spark、Qwen3.8、Qwen-VL、GLM-OCR、BGE-M3、Reranker 和 CosyVoice，期间各模式不可同时提供服务。全部通过后恢复测试开始时的模式。若某模式失败，立即停止后续测试，不自动复位设备、不强行恢复加载；保留报告并由维护人员处理。探针证明执行链路可用，不代表识别准确率或长期稳定性已经验收。

断网重启验收步骤：

- 保持盒子无互联网连接；可以保留本地管理网络。
- 安装与验收完成后执行 `sudo reboot`，等待系统和默认服务启动。
- 确认管理页面可访问，`sudo modelctl status` 显示配置模式与检测模式一致。
- 回到交付目录再次运行 `sudo python3 scripts/verify_runtime.py`，确认报告中的 `passed` 为 `true`。
- 保存安装日志、默认/全模式验收报告和重启后报告。报告文件会被下一次验收覆盖，应在每次测试后另行复制归档。

## 8. 常见问题与安全处理

| 现象 | 处理方法 |
| --- | --- |
| 校验失败、文件缺失 | 停止安装，重新拷贝大包及校验文件；不跳过检查。 |
| 架构、系统或驱动不匹配 | 使用经过确认的同型号厂家系统；不要改脚本绕过检查。 |
| 已有项目或 Docker 容器 | 本包不覆盖现有部署；联系维护人员制定迁移或升级方案。 |
| 缺少基础系统组件 | 由系统维护人员补齐匹配的厂家基础环境；本安装器不联网补装。 |
| 磁盘空间不足 | 分别检查项目目录与 Docker 数据目录所在分区；不要删除生产数据腾空间。 |
| 中断后无法直接重新安装 | 使用同一个包的 `--resume`；不得修改阶段记录来跳过故障。 |
| 镜像缺失且没有自动拉取 | 这是离线保护；复核全包校验和与镜像导入日志。 |
| NPU 隔离、模式切换失败 | 停止重复加载，保存日志，在 UI 运行诊断中按维护流程处理。 |
| 票据返回 review | 需要人工复核；不等同于接口失败，不应把结果当作全部可靠。 |

常用只读排查命令：

```
sudo docker ps -a
sudo modelctl status
sudo systemctl status houmo-ai ai-model-gateway gateway-admin
sudo journalctl -u houmo-ai -n 100 --no-pager
df -h /home/cix /var/lib/docker
```

不要执行 `docker system prune`、删除模型目录、覆盖 `.env` 或自动重置加速器作为通用排障步骤。诊断文件对外发送前应检查是否包含凭据或业务内容。

## 9. 安装后的文件保留与交付签收

安装并完成重启验收后，可以由维护人员归档或移走原始 TAR 和解压安装目录，以释放空间。清理前应保留本版本的安装说明、校验文件、版本清单和验收记录；之后再次运行交付验收工具需要重新解包。

不能清理实际运行目录 `/home/cix` 下的项目、模型与固定运行环境，也不能清理 Docker 数据目录。升级与自动回滚不属于本包功能；后续版本更新需要单独的升级交付流程。

交付签收应记录：设备型号与编号、系统/驱动版本、包的 SHA-256、安装时间、默认模式、全模式验收结果、断网重启结果和遗留问题。源盒子的历史验收结果不能替代新盒子的验收记录。